

# 50 Startups 利潤預測與決策分析

---

基於 CRISP-DM 方法論與機器學習的資金配置指引



---

# 專案執行摘要

從數據清洗、機器學習建模到 Streamlit 雲端部署，提供直觀、精準的  
新創投資決策依據。



# 商業與資料理解

---

## 核心商業目標

利用企業在各項營運成本的投入，精準預測其產出的淨利潤 (Profit)，為創投公司與新創孵化器提供資金配置的科學依據。

## 資料集特徵

- 共 50 筆新創公司財務記錄。
- 3 項數值特徵：研發支出、行政管理、行銷推廣。
- 1 項類別特徵：所在地區 (State)。
- 1 項目標變數：淨利潤 (Profit)。

 Startup business meeting strategy



---

# 數據清洗與準備

高品質的特徵工程是精準預測的基石。我們遵循嚴格的統計標準處理  
極端值、零值與共線性問題。



# 極端值精準剔除 (IQR Filter)

---

**\$14,681**

**Index 49 利潤極低值**

## 防範迴歸線扭曲

我們利用四分位距 (IQR) 檢驗目標欄位 Profit，發現 Index 49 的利潤低於正常門檻 (\\$15,698)。

該公司研發支出為 0，行政開銷高達 11.7 萬，呈現極度異常的營運結構。將其從訓練集中剔除，能有效防止線性迴歸模型的權重產生嚴重偏斜。



# 數據完整性與編碼策略

---

- ✔ **保留真實業務的 0 值：** 數據集中部分研發與行銷支出為 0。這些代表草創期或無行銷預算的真實商業模式，並非缺失值，因此我們不進行任何平均值填補，以維持資料真實性。
- 🛡️ **防範虛擬變數陷阱：** 針對地理位置 (State) 進行 One-Hot 編碼時，我們設定剔除基準地區（加州）。此舉能有效消除完美多重共線性 (Dummy Variable Trap)，確保線性迴歸假設成立。
- ⚖️ **選擇性特徵縮放：** 為了讓迴歸係數具備可比性，我們僅針對三個「連續型數值特徵」使用 StandardScaler 進行標準化；地區二元虛擬變數則保持原樣不縮放，以維持高度的商業可解釋性。



---

# 機器學習建模與效能對比

將資料依 80/20 比例切分，構建並評估多個預測模型，找出最適解。



# 五大迴歸模型擴展矩陣

---



## 線性與正則化

包含多元線性迴歸 (OLS) 與 **Ridge 脊迴歸**。提供極佳的數學可解釋性，適合判讀各項特徵對利潤的絕對影響權重。



## 非線性支援向量

引入 **SVR (支援向量迴歸)**。在處理高維度或邊界複雜的資料集時，能提供不同於傳統線性的預測視角。



## 樹狀整合演算法

部署 **隨機森林 (Random Forest)** 與 **梯度提升樹 (Gradient Boosting)**。透過多棵決策樹整合，極大化預測準確度並捕捉非線性交互作用。



# 測試集定量效能對比

| 評估模型                                                                                                         | R-squared (解釋力) | 平均絕對誤差 (MAE) |
|--------------------------------------------------------------------------------------------------------------|-----------------|--------------|
| 隨機森林迴歸 (Random Forest)                                                                                       | 0.9260          | \$6,892.37   |
| 多元線性迴歸 (Linear Regression)                                                                                   | 0.9190          | \$6,550.86   |
| <p>對比結論：</p> <p>隨機森林模型在解釋力上表現最佳，能解釋 92.6% 的利潤變異。而線性迴歸的誤差極低，相較於平均 11.2 萬美元的利潤，其誤差率僅約 5.8%，兩者皆具備極高的實務預測價值。</p> |                 |              |



---


# 特徵權重與重要性分析

揭開黑盒子，量化各項營運決策對最終淨利潤的實際貢獻度。



# 線性迴歸：標準化特徵權重


圖示反映當該特徵增加 1 個標準差時，利潤的變化幅度 (美元)：



在未縮放的真實情境中，研發費用每增加 \$1，利潤預期增加 **\$0.81**；而行銷費用每增加 \$1，利潤僅微增 **\$0.03**。



# 隨機森林：特徵重要性佔比



樹狀模型的分裂貢獻度高度一致地指出：研發投入是預測新創獲利的絕對決定性特徵，而地理位置幾乎無影響力。



---

# 高階商業決策與建議

將數據模型洞察轉化為具體的資金配置戰略 (100萬美金該投在哪?)



# 黃金法則一：研發是獲利核心引擎

---

- **壓倒性的重要性：**無論在哪一種模型中，研發支出 (R&D) 的重要性皆超過 90%。
- **高額預期回報率：**每額外投入 \$1 的研發資金，可帶來高達 \$0.81 的新增利潤 (回報率 81%)。
- **顧問戰略建議：**企業與創投應將資金集中配置於技術創新與產品優勢建立。建議將總預算的 80%~85% 優先鎖定在研發部門，構築堅實的護城河。

 Tech innovation lab



# 黃金法則二與三：優化行銷、精簡行政

---

## 🎯 優化行銷配置 (Marketing)

行銷雖然與利潤呈正相關，但其邊際效益非常低（每 \$1.00 投入僅回收 \$0.03 的利潤增長）。

**建議：**不應盲目擴大行銷預算。行銷活動必須朝向高度精準定位與提高轉換率進行優化，以確保預算花在刀口上。

## ⚡ 精簡行政開銷 (Administration)

資料顯示，行政支出對利潤帶來微弱的負向效應（每 \$1.00 倒扣 \$0.07 利潤）。

**建議：**龐大的行政組織是單純的成本負擔。如同被剔除的 Index 49 公司（高行政、零研發導致獲利見底），企業應極力精簡流程與日常營運開銷。



## 黃金法則四：地理選址策略

---

在排除虛擬變數陷阱後，三個州之間的獲利並無顯著差異。新創選址應以「營運成本最低」為唯一考量，毋需迷信創業熱點。

— 區域決策模型洞察 (影響力 < 0.2%)



---

# 統計檢定與深度觀察

為確保模型的穩健性與決策可靠度，我們進行了三項深度的統計實驗。



# 三大模型深度驗證



## 共線性檢驗 (VIF)

為避免研發與行銷預算互相干擾，我們計算了變異數膨脹因子。R&D 與 Marketing 的 VIF 均低於 2.5 (安全標準  $< 5$ )，證明兩特徵獨立發揮作用，權重判斷具高信賴度。



## 地區特徵刪除對比

完全移除地理位置 (State) 特徵後，模型對利潤的整體解釋力 ( $R^2$ ) 僅微幅下降 **0.05%**。進一步在統計上證實了地區變數並非獲利的決定因子，模型可考慮簡化。



## 極端值的權重扭曲力

若不剔除 Index 49 的極端數據，會導致佛州 (Florida) 的迴歸係數符號**由負轉正**。這印證了 OLS 對異常點的高敏感性，突顯前期 IQR 清洗對避免錯誤商業決策的絕對必要性。




# 系統架構與互動體驗升級

 Lightning fast speed

## 向量化極速運算

最佳化搜尋演算法重構為批量計算，耗時從 2000 毫秒縮減至 **0.005 秒內**，介面達到即時秒響應。



## 全互動視覺化 (Plotly)

圖表全面升級，支援使用者拖曳滑桿設定預算，介面中的散佈圖與箱型圖會實時連動顯示「模擬公司」的獲利位階。

 Cloud servers

## 一鍵雲端與動態重訓

無縫部署至 Streamlit Cloud。支援線上傳自訂 CSV，系統將於 0.05 秒內自動清洗數據並重訓 5 大模型更新介面。



# Q & A

感謝您的聆聽，歡迎提問與探討。

50 Startups Data Science Team | 商業決策與模型洞察報告



# Image Sources

---



Thumbnail  
for

[https://cdn.prod.website-files.com/65b212ea8e0b38fa0a23f1e9/68c2829b22909bf4bf9c307a\\_65e6ebdb4fd5056da00c0b84\\_events\\_intro.png](https://cdn.prod.website-files.com/65b212ea8e0b38fa0a23f1e9/68c2829b22909bf4bf9c307a_65e6ebdb4fd5056da00c0b84_events_intro.png)

Source: [setting.io](https://setting.io)



Thumbnail for

[https://img.magnific.com/free-photo/interior-empty-science-laboratory-with-modern-equipment-prepared-pharmaceutical-innovation-using-high-tech-microbiology-to-boost-scientific-research-vaccine-development-against-covid19-virus\\_482257-12800.jpg?semt=ais\\_hybrid&w=740&q=80](https://img.magnific.com/free-photo/interior-empty-science-laboratory-with-modern-equipment-prepared-pharmaceutical-innovation-using-high-tech-microbiology-to-boost-scientific-research-vaccine-development-against-covid19-virus_482257-12800.jpg?semt=ais_hybrid&w=740&q=80)

[www.magnific.com](https://www.magnific.com)



Thumbnail for

[https://static.vecteezy.com/system/resources/thumbnails/035/267/070/small\\_2x/ai-generated-digital-cyberspace-with-particles-and-digital-data-network-connections-high-speed-connection-and-data-analysis-technology-digital-abstract-background-concept-3d-rendering-photo.jpg](https://static.vecteezy.com/system/resources/thumbnails/035/267/070/small_2x/ai-generated-digital-cyberspace-with-particles-and-digital-data-network-connections-high-speed-connection-and-data-analysis-technology-digital-abstract-background-concept-3d-rendering-photo.jpg)

[www.vecteezy.com](https://www.vecteezy.com)



Thumbnail  
for

<https://cdn.dribbble.com/userupload/43507872/file/original-df7180b18e97f8487d50bd65cba0a013.png>

Source: [dribbble.com](https://dribbble.com)

[dribbble.com](https://dribbble.com)



[https://images.stockcake.com/public/6/3/6/63677c7b-6deb-4501-912b-d829d4ba2761\\_large/cloud-computing-infrastructure-stockcake.jpg](https://images.stockcake.com/public/6/3/6/63677c7b-6deb-4501-912b-d829d4ba2761_large/cloud-computing-infrastructure-stockcake.jpg)

Source: [stockcake.com](https://stockcake.com)



Thumbnail for

[https://static.vecteezy.com/system/resources/previews/070/335/914/non\\_2x/abstract-digital-wireframe-background-with-glowing-dots-and-circular-shapes-on-a-dark-blue-gradient-perfect-for-technology-data-futuristic-space-and-science-design-themes-vector.jpg](https://static.vecteezy.com/system/resources/previews/070/335/914/non_2x/abstract-digital-wireframe-background-with-glowing-dots-and-circular-shapes-on-a-dark-blue-gradient-perfect-for-technology-data-futuristic-space-and-science-design-themes-vector.jpg)

[www.vecteezy.com](https://www.vecteezy.com)