

# 50 Startups 利潤預測與決策分析專案

技術白皮書與商業決策指引報告 (Technical Whitepaper)

專案名稱: 50 Startups Profit Prediction

發佈日期: 2026 年 6 月 12 日

協作開發: Gemini (Antigravity)

架構標準: CRISP-DM 數據科學流程

專案路徑: hirohirolee/My-Learning-Journey

系統版本: Web App v1.2 (Optimized)

前言: 本白皮書完整彙整了基於 CRISP-DM 流程的新創公司利潤預測專案。內容包含高階商業決策 ( Executive Summary )、雙語統計與機器學習技術報告 ( Technical Analysis )、系統效能與程式優化日誌 ( Change Logs ) 以及完整的雲端部署指引。旨在為投資人、創始人以及技術開發團隊提供全方位的商業與技術對照手冊。

# 第一篇：高階商業決策與互動分析 (Executive Summary)

本章節專為經營決策層設計，以最直觀的商業語言總結 50\_Startups 專案模型的核心發現與決策指引，避開生硬的數學公式。

## 1. 模型總結：預測利潤到底準不準？

- 結論：極度精準！本模型可解釋市場上 92.6% 的新創年利潤變化。
- 在測試新創公司時，平均預測誤差僅在 \$6,500 左右。相對於公司平均 \$11.2 萬的年利潤，誤差率僅為 5.8%，具有極高的實務參考價值。

## 2. 資金配置黃金法則：100 萬美金該投在哪？

- 黃金分配：壓倒性投入「研發 (R&D)」，行銷適量，行政費用越低越好。
- 研發 (R&D)：每多投入 \$1.00，預期帶回 \$0.81 的新增利潤 (回報率達 81%)。
- 行銷 (Marketing)：每多投入 \$1.00，預期帶回 \$0.03 的新增利潤 (回報率僅 3%)。
- 行政 (Admin)：每多投入 \$1.00，利潤反而倒扣 \$0.07 (為淨損失、負向效應)。
- 顧問建議：優先撥出 80%~85% 的預算投入研發以確保產品核心優勢，15% 進行精準行銷，並嚴格控管行政管理成本。

## 3. 地區決策與選址分析

- 結論：三個州獲利無顯著差異，選擇「營運成本最低」的地方即可。地理位置對利潤的預測影響力低於 0.2%。新創公司無需迷信「加州」等高成本熱點，哪裡租金低、稅率划算，就是最好的選址。

## 4. 異常點啟示：Index 49 給我們的警示？

- 被剔除的 Index 49 公司呈現了典型的失敗特徵：「重行政、輕產品，無核心競爭力」。該公司研發支出為 \$0，行銷花了 \$4.5 萬，而行政費用卻高達 \$11.7 萬，最終只換來 \$1.4 萬的利潤。這警告我們：沒有技術研發，只靠行銷與虛胖的行政組織是行不通的。

## 5. 直觀圖表視覺化 (Executive Visuals)

下圖展示了新創公司利潤決定因子的權重排行，研發以 91.7% 的決策權重佔據絕對主導地位，行銷占 7.3%，其餘特徵均小於 1%：




圖 1: 新創公司利潤驅動因子重要性排行 (研發支出佔絕對主導 91.7%)

下圖為實際值與預測值的對比圖，藍色圓點代表測試集中的真實公司，紅色斜虛線代表完美預測線。所有藍色點均緊貼在紅色虛線兩側，並未出現大幅度偏離，證明模型的實際預估能力極強：




圖 2: 預估利潤 vs 真實利潤散佈圖 (測試集  $R^2$  可解釋度達 92.6%)

# 第二篇：CRISP-DM 雙語技術與統計分析報告 (Technical Analysis)

本章節詳述針對 50\_Startups.csv 資料集進行的統計清洗、資料工程與機器學習建模評估。

## 2.1 商業與資料理解 (Business & Data Understanding)

本專案的核心目標是利用企業在研發支出 (R&D; Spend), 行政管理 (Administration), 行銷推廣 (Marketing Spend) 的投入以及所在的地區 (State), 來精準預測其產出的利潤 (Profit)。資料集包含 50 筆記錄，其中含有 3 項連續型支出特徵、1 項地區類別特徵以及 1 項 Profit 目標變數。

## 2.2 數據清洗與準備 (Data Preparation)

- 1) 極端值剔除 (IQR Outlier Filtering): 利用四分位距 (IQR) 檢驗目標欄位 `Profit` 的分布。計算出 IQR 為 \$49,627.07，極端低值門檻為 \$15,698.29，極端高值門檻為 \$214,206.59。偵測發現 Index 49 的 Profit 為 \$14,681.40，低於門檻，判定為異常值並直接剔除。剔除後建模樣本數為 49 筆，可防範異常值干擾迴歸線擬合。
- 2) 0 值處理 (Zero Values): 數據集中 Index 19, 47, 48 包含部分 0 值。這些代表草創或不投放行銷的真實業務狀況，因此保持原樣，不進行插值填補。
- 3) 類別編碼與防共線 (Encoding): 針對類別變數 `State` (加州/佛州/紐約) 進行 One-Hot 編碼，並設定 `drop\_first=True` 剔除基底地區 (加州)，僅保留 `State\_Florida` 與 `State\_New York`。此舉能有效避開虛擬變數陷阱 (Dummy Variable Trap)。
- 4) 特徵縮放 (Feature Scaling): 僅針對 `R&D; Spend`, `Administration`, `Marketing Spend` 等數值連續欄位套用 `StandardScaler`；One-Hot 編碼虛擬變數則維持 0-1 不縮放以保留可解釋性。

## 2.3 模型建立與效能對比 (Modeling & Evaluation)

我們將資料集切分為 80% 訓練集與 20% 測試集，並訓練了多個迴歸模型進行對比。以下為兩款核心模型的效能評估：

| 評估模型 (ML Model)                  | 解釋能力 (R-squared) | 平均絕對誤差 (MAE) |
|----------------------------------|------------------|--------------|
| 多元線性迴歸 (Linear Regression - OLS) | 0.91908          | \$6,550.86   |
| 隨機森林迴歸 (Random Forest)           | 0.92601          | \$6,892.37   |

## 2.4 特徵權重與重要性分析 (Feature Weights & Importance)

多元線性迴歸特徵權重 (標準化係數)：研發支出 (+34,885.07) > 行銷支出 (+4,342.70) > 行政管理 (-425.04)。地理位置虛擬變數則小於 0.2% 影響力。這表明研發支出是主導獲利的第一驅動力。

複線性迴歸數學方程式 (原始數據):

Profit = 51,306.76 + 0.7619 \* (R&D; Spend) - 0.0147 \* (Administration) + 0.0400 \* (Marketing Spend) - 1860.88 \* (State\_Florida) - 2877.86 \* (State\_New York)

## 2.5 專案深度觀察與統計檢定

- 共線性檢驗 (VIF)：計算出各支出特徵之變異數膨脹因子 ( R&D; Spend VIF: 2.40 · Marketing Spend VIF: 2.32 · Admin VIF: 1.18 )，皆小於臨界值 5，驗證無顯著共線性，係數具備高信賴度。
- 地區消融實驗 (Ablation Test)：包含地區時 OLS解釋力為 96.18%；完全剔除地區特徵後為 96.13%。模型解釋力僅微幅下降 0.05%，證實設點州別無實務顯著影響。
- 異常點敏感性檢驗：若不剔除異常值 Index 49，佛州係數為正數 (+\$198.79)；剔除異常值後，佛州係數轉為負數 (-\$1,564.22)，證明 OLS 對單一極端值具有高敏感性，印證了 IQR 清洗的重要性。

逐步特徵篩選評估與 9 種特徵選擇演算法對照表 (Feature Selection Study)：




圖 3: 9 種特徵篩選算法隨特徵數增加之指標收斂對比 (摘自 L6 50 Startup 專案篩選圖像)

## 第三篇：系統變更與今日優化全紀錄 (Change & Modification Logs)

本章節總結了專案程式碼變更日誌，包含架構與效能重構、Plotly 視覺化升級以及 Bug 修復。

### 3.1 架構與效能重構

- 演算法模型擴展：由原本的 2 種模型擴充為 5 種 ( 多元線性迴歸、脊迴歸、SVR、隨機森林、梯度提升迴歸 )，並在 Streamlit Web 排行榜中動態高亮最優模型。
- 最佳化向量化重構 (Vectorization)：將預算配置搜尋邏輯從單筆迴圈改寫為 NumPy 向量化批量運算。最佳化運算時間從 2,000 毫秒縮短至 5 毫秒 ( 0.005 秒 ) 以內，徹底消除介面卡頓，實現即時秒響應。

### 3.2 互動式視覺化優化

- 對數尺度 Y 軸 (Log Scale)：針對各模型 MSE 差距大導致底層折線擠壓的問題，新增 Log Scale 切換控制 ( 預設開啟 )，拉開並分離折線，解決線條擠壓問題。
- 演算法多選篩選器 (Multi-Select)：側邊欄配置勾選選單，可動態顯示/隱藏特定模型。

## 第四篇：雲端與本地端部署指南 (Deployment Guide)

### 4.1 本地運行指南

在本地端運行 Streamlit Web 應用程式，請執行以下步驟：

```
# 1. 安裝 Python (3.9+) python --version # 2. 安裝 requirements.txt pip install -r requirements.txt # 3. 安裝 Streamlit streamlit run app.py
```

### 4.2 Streamlit Community Cloud 部署設定

1. 將所有程式碼 ( 包含 50\_Startups.csv ) 推送至 GitHub `My-Learning-Journey` 的主分支。
2. 登入 Streamlit Share，點擊 New App 並設定：
  - Repository: hirohirolee/My-Learning-Journey
  - Branch: master
  - Main file path: daily\_lessons/20260609/huanclass/app.py
3. 點擊 Deploy! 部署。1-2 分鐘後容器啟動即可獲取專屬公網網址。